Resolver un problema de clasificación.

June 14, 2021

- 1 Actividad Número 3, Técnicas Multivariantes.
- 1.1 Máster en ingeniería matemática y computación.
- 1.2 Jorge Augusto Balsells Orellana.

```
[1]: | #!/usr/bin/python3
```

1.2.1 Importación de librerías

```
[2]: import matplotlib.pyplot as plt
import statsmodels.api as sm
import sklearn as sk
import numpy as np
import pandas as pd
import graphviz
import seaborn as sns
```

1.2.2 Creando dataset.

1.2.3 Documento de identificación: 1663153890101 -> Modificado: 26632538

```
weights=None,
         flip_y=0.01,
         class_sep=1.0,
         hypercube=True,
         shift=0.0,
         scale=1.0
 )
 #Longitud de dataset
 print("Length: " + str(len(DataSet)))
 X = DataSet[0]
 Y = DataSet[1]
 #Shapes con el tamaño de los arrays involucrados en DataSet
 print("Generated Samples:" + str(X.shape))
 print("Integer labels:" + str(Y.shape))
 print("El conjunto de datos contiene "+str(X.shape[1])+" variables predictoras, ⊔
   →con "+str(X.shape[0])+" muestras")
 #Agregando nombres de columnas a DataSet
 Features =
   پر ['c0','c1','c2','c3','c4','c5','c6','c7','c8','c9','c10','c11','c12','c13','c14', المالية 
  Data = pd.DataFrame(DataSet[0], columns = Features)
 print(Data)
Length: 2
Generated Samples: (220, 22)
Integer labels:(220,)
El conjunto de datos contiene 22 variables predictoras, con 220 muestras
                       c0
                                            c1
                                                                 c2
                                                                                      сЗ
                                                                                                            c4
                                                                                                                                 c5
        -0.623798 2.886848 2.289823 1.966687 5.857388 2.864425 1.240953
0
     -4.230493 2.574538 -1.888288 0.034745 0.474872 -3.073048 -3.280422
1
         2.403653 -0.138274 3.773707 2.264375 4.246538 0.156183 3.108223
     -2.314204 -2.136062 0.104248 2.047772 -0.883033 -4.931123 -1.713463
3
4
        -1.859431 -1.098524 0.552397 5.169887 1.383473 -1.257396 4.124868
215 -4.483727 -2.943545 1.243704 3.460865 0.145977 1.130336 -1.093742
216 -2.571963 3.924738 3.771498 -0.270276 1.586456 2.028533 4.302808
217 -1.107106 2.239045 -2.226861 -0.669305 -2.780989 0.468113 -2.042945
218 -3.406655 3.023067 -6.719494 2.827009 -0.320336 -2.108107 -3.761495
219 4.003681 -0.878472 -2.034100 -1.018294 -2.088653 4.197321 0.759902
                       с7
                                                                                                                                          c14 \
                                            с8
                                                                 с9
                                                                                               c12
                                                                                                                    c13
0
        -0.519994 0.466540 -2.240870 ... -5.508834 -2.004952 -4.410966
        -5.113795 -2.293789 3.113564
                                                                        ... 8.674391 2.086394 2.838027
```

```
-1.907037 -3.568915 -3.096199 ... -3.513964 1.267124 -4.145067
3
   -0.655707 -1.854736 -0.733168
                                  3.756722 1.588267 1.103204
4
    2.787510 1.222891 2.233237
                                  0.919870 3.427640
                                                   2.300415
. .
215  0.931300  -2.070931  -1.808822
                             ... 3.219543 -1.258340 3.718142
216 2.677844 -0.692493 -3.135414
                                           1.785074 -3.016355
                              ... 1.140616
217 -0.294405 1.369012 -2.065447
                              ... -0.415357 -3.724343 1.699928
218 3.270016 3.113855 0.599535
                              ... -1.411823 -0.227754 -1.022757
219 2.902194 5.646378 1.757992 ... -0.853214 -0.563142 -0.183372
                  c16
        c15
                           c17
                                    c18
                                             c19
                                                      c20
                                                              c21
   -6.332895 -13.716803
                               0.303550 -0.863660 0.106751 -0.997125
0
                       0.886687
             1
    3.845933
2
   -3.132932 -9.629241 -0.500882 0.877463 0.713304 0.370858 0.799430
3
   -1.747323 -0.558611 -0.750382 -0.251319 1.013492 -0.070628 -1.958347
   -1.669274 -4.316897
                       4.477207 -0.064378 2.333631 -0.639747 -1.355723
215 -0.464070 -3.788584
                       0.444629 0.290284 0.990517 0.993528 -1.160651
216 1.916252 -5.114002 -1.794398 1.008627 -0.199072 -0.690215 1.526858
217 -0.219343 -1.656995 -4.320898 -0.245096 2.728810 1.447858 -0.030568
219 5.115366
             6.597616
                       7.785048 -0.655601 -0.558329 -0.012811 0.365807
[220 rows x 22 columns]
```

1.2.4 Divide el conjunto de datos en 200 observaciones para el entrenamiento y el resto para realizar la validación de los distintos métodos de regresión aplicados.

```
[4]: #Separacion de datos de entrenamiento y datos de prueba
TrainSet, TestSet = train_test_split(Data, test_size=0.09, random_state=42)
YTrain, YTest = train_test_split(Y, test_size=0.09, random_state=42)

#Mostrar shape de datos de entrenamiento
print("Datos de entrenamiento")
print(TrainSet.shape)
print(YTrain.shape)

#Mostrar shape de datos de prueba
print("Datos de prueba")
print(TestSet.shape)
print(YTest.shape)
```

Datos de entrenamiento (200, 22) (200,) Datos de prueba (20, 22) (20,)

1.2.5 Describe tu conjunto de datos (transfórmalo en un data.frame, aplica los métodos .info(), .describe() y obtén el histograma o diagrama de barras de todas las variables (predictoras y la variable respuesta).

```
[5]: TrainSet.info()
```

<class 'pandas.core.frame.DataFrame'> Int64Index: 200 entries, 189 to 102 Data columns (total 22 columns): Column Non-Null Count Dtype float64 0 c0 200 non-null 1 200 non-null float64 c1 2 c2 200 non-null float64 3 сЗ 200 non-null float64 4 200 non-null float64 c4 5 с5 200 non-null float64 6 200 non-null float64 с6 7 c7 200 non-null float64 8 с8 200 non-null float64 9 с9 200 non-null float64 200 non-null float64 10 c10 11 c11 200 non-null float64 12 c12 200 non-null float64 200 non-null 13 c13 float64 14 c14 200 non-null float64 15 c15 200 non-null float64 c16 200 non-null float64 16 200 non-null float64 17 c17 18 c18 200 non-null float64 200 non-null 19 c19 float64 20 c20 200 non-null float64 21 c21 200 non-null float64

dtypes: float64(22) memory usage: 35.9 KB

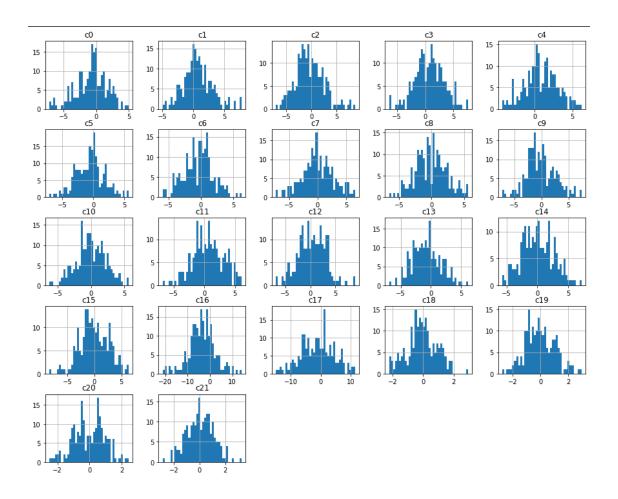
[6]: TrainSet.describe()

[6]: c0 c2 с3 c4 c5 c1 200.000000 200.000000 200.000000 200.000000 200.000000 200.000000 count 0.720671 -0.545805 mean -0.704091-0.321631 0.728076 0.817680 std 2.374237 2.313069 2.807653 2.581373 2.148528 2.303483 min -7.219070 -4.926262 -7.056635 -6.387122 -4.329674 -7.129064 25% -2.222519 -0.601004 -2.154710 -0.913317 -0.553274 -2.192671 50% 0.499173 -0.603888 -0.569562 0.773361 0.631153 -0.443027

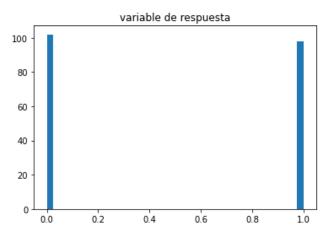
```
75%
          0.941912
                      1.892434
                                   1.258851
                                                2.495485
                                                             2.300333
                                                                          0.697737
                                                             6.213770
          4.990854
                      7.784950
                                   8.644422
                                                7.613113
                                                                          5.714544
max
                с6
                             c7
                                                       с9
                                                                        c12 \
                                          с8
                                                           . . .
       200.000000
                    200.000000
                                 200.000000
                                              200.000000
                                                                200.000000
count
                                                           . . .
        -0.381539
                     -0.013848
                                  -0.090832
                                               -0.124847
                                                                  0.341815
mean
                                                           . . .
std
         2.200018
                                                2.662448
                                                                  2.728096
                      2.764656
                                   2.355375
                                                           . . .
min
        -5.911245
                     -7.316625
                                  -6.528675
                                               -7.193691
                                                                 -6.874284
25%
                                               -1.894179
        -1.805663
                     -1.740198
                                  -1.786658
                                                                 -1.580786
50%
        -0.230165
                     -0.152530
                                  -0.227420
                                               -0.394961
                                                                  0.382955
                                                           . . .
75%
         0.949454
                      1.724729
                                   1.430562
                                                1.639940
                                                           . . .
                                                                  2.310996
          6.296661
                      6.515889
                                   5.646378
                                                7.384637
                                                                  8.899354
max
                                                           . . .
               c13
                            c14
                                         c15
                                                      c16
                                                                   c17
                                                                               c18
                                                                                     \
       200.000000
                    200.000000
                                 200.000000
                                              200.000000
                                                           200.000000
                                                                        200.000000
count
                                                                         -0.067145
mean
        -0.772603
                      0.027777
                                  -0.056464
                                               -3.626522
                                                            -1.082637
std
         2.303506
                      2.544115
                                   2.641034
                                                5.799857
                                                             5.468672
                                                                          0.968266
                                              -21.167742
                                                           -14.961184
                                                                         -2.228178
min
        -6.921811
                     -5.682946
                                  -8.346379
25%
        -2.519280
                     -1.843186
                                  -1.670472
                                               -7.034478
                                                            -5.264901
                                                                         -0.658488
50%
        -0.869128
                     -0.073868
                                  -0.238759
                                               -3.734389
                                                            -0.830931
                                                                         -0.109493
75%
         0.624991
                      1.751848
                                   1.936141
                                               -0.313455
                                                             2.755951
                                                                          0.594224
         6.178711
                      7.142610
                                   6.338418
                                               14.213284
                                                            11.367014
                                                                          2.957483
max
               c19
                            c20
                                         c21
       200.000000
                    200.000000
                                 200.000000
count
mean
        -0.031876
                     -0.027911
                                   0.055325
std
         1.054385
                      0.951471
                                   1.033747
min
        -2.753712
                     -2.500636
                                  -2.886508
25%
        -0.789839
                     -0.685702
                                  -0.653257
50%
        -0.131189
                     -0.011032
                                   0.025438
75%
         0.735761
                      0.636113
                                   0.780903
         2.972162
                      2.419877
                                   3.293263
max
```

[8 rows x 22 columns]

```
[7]: #40 barras, tamaño de 15x12
TrainSet.hist(bins=40,figsize=(15,12))
plt.title("variables predictoras")
plt.show()
```



```
[8]: #Máximo de 40 barras
plt.hist(YTrain,bins=40)
plt.title("variable de respuesta")
plt.show()
```



1.2.6 Obtén un modelo de clasificación mediante un árbol de decisión. Utiliza la función DecisionTreeClassifier de la librería scikit-learn utilizando los argumentos por defecto.

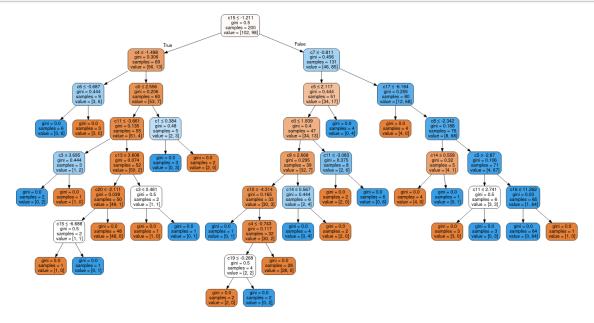
```
[9]: #Entrenamiento árbol de decisión
CLFDefault = DecisionTreeClassifier()
CLFDefault = CLFDefault.fit(TrainSet, YTrain)

YPred = CLFDefault.predict(TestSet)

AccuracyTreeDefault = accuracy_score(YPred, YTest)
AccuracyTreeDefault
```

[9]: 0.75

[22]:



1.2.7 Ahora indica que el nivel de profundidad máximo permitido es de 3. ¿Qué diferencias observas con el árbol anterior?

La principal diferencia es la profundidad que se le ha configurado, ya que el primero no tenía restricciones de profundidad. En este caso la profundidad máxima es de 3, lo cuál significa que, luego del nodo inicial, tenemos 3 niveles más en el árbol. Al ser un árbol binario, la máxima cantidad de nodos alcanzados en la última capa es de 8 nodos(2^n). Esto significa que el árbol original, solo es considerado hasta su tercera capa.

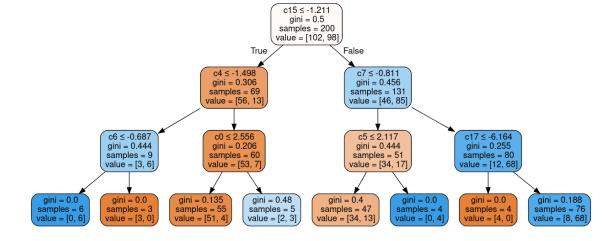
```
[11]: #Entrenamiento de árbol de decisión con un máximo de 3 niveles de profundidad
CLFMaxDepth3 = DecisionTreeClassifier(max_depth=3)
CLFMaxDepth3 = CLFMaxDepth3.fit(TrainSet, YTrain)

YPred = CLFMaxDepth3.predict(TestSet)

AccuracyMaxDepth3 = accuracy_score(YPred, YTest)
print(AccuracyMaxDepth3)
```

0.8

[12]:



1.2.8 Realiza los siguientes modelos de ensamble:

- Con reemplazamiento (bagging).
- Sin reemplazamiento (pasting).
- Realizando Random Forest (fijando el número de nodos hoja máximo a 4).
- GBM.

¿Cuál es mejor?

1.2.9 Bagging, con reemplazamiento

0.9

1.2.10 Pasting, sin reemplazamiento

0.85

1.2.11 Random forest

0.85

1.2.12 GBM, Gradient Boosting Classifier

0.85

1.2.13 Cuál método es mejor?

El mejor método es el más preciso, en este caso, el de mayor precisión es "Bagging".

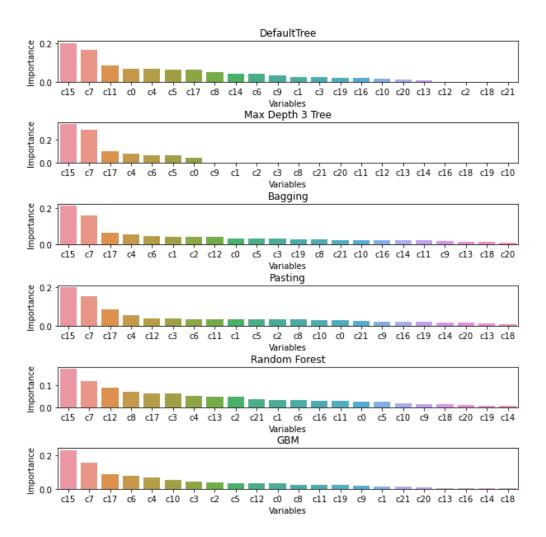
```
Model Accuracy
0 Bagging 0.90
1 Pasting 0.85
2 Random Forest 0.85
3 GBM 0.85
```

1.2.14 Analiza la importancia de las variables de cada uno de estos métodos.

```
[19]: Features = np.array(Features)
      fig, axs = plt.subplots(
          nrows=len(ModelsNames),
          figsize=(10,10)
          )
      fig.suptitle("Variables Importance")
      for i,modelo in enumerate(Models):
          order_index = np.argsort(importances[i])[::-1]
          sns.barplot(
              x=Features[order_index],
              y=importances[i][order_index],
              ax=axs[i]
              )
          axs[i].set_title(ModelsNames[i])
          axs[i].set_xlabel("Variables")
          axs[i].set_ylabel("Importance")
```

```
plt.subplots_adjust(hspace=1)
plt.show()
```

Variables Importance



[]:

References

- [1] Aurélien Géron. Hands-on Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. O'Reilly Media.
- [2] Scikit-Learn. Decisiontreeclassifier. https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.html.
- [3] Seaborn. Seaborn barplot. http://seaborn.pydata.org/generated/seaborn.barplot.html.